LABORATUVAR 7 · MOSTRO 1000 · Kalibre Zımpara

AI Safety Challenge

Çıktı: AI Fail-Safe Decision

Ad Soyad | Grup | Tarih

Kavram — Prediction ≠ Safety: Yapay zekâ bir karar üretir; güvenliği garanti eden mimari YZ'nin **dışında** tanımlanmalıdır.
Araçlar: fail-safe · human override · monitoring · confidence threshold · fallback.

Kamera → YZ Modeli → OK / RED → Parametre → Robot

Görev — üç başarısızlıkta güvenli davranış

1. **Model yanlış sınıflandırdı:** Kusurlu parçaya OK verdi. Sistem ne yapmalı? İkinci kontrol / insan onayı var mı?

Ölçüm YZ'si tek başına kalınlık kararı vermez. İkinci bağımsız ölçüm (mekanik/lazer) ve örnekleme; kritik ölçü sapmasında insan onayı. Hata oranı eşik üstüne çıkarsa hat durur.

2. **Girdi manipüle edildi:** Kamera verisi bozuk/sahte. Nasıl fark edilir? Şüpheli girdide ne yapılır?

Bütünlük kontrolü (görüntü istatistiği, donmuş kare, zaman kontrolü), sensör öz testi. Şüpheli girdide parça reddedilir, makine durdurulur ve insana bildirilir. 'Geçir' varsayılanı yok.

3. **Confidence düştü:** Model "emin değilim" diyor. Eşik ne olmalı? Altında: dur / insana sor / fallback?

Eşiğin altında otomatik ölçü kabulü yok. Önce insana sorulur; belirsizlik sürerse güvenli varsayılan (dur/ret). Eşik risk değerlendirmesiyle kalibre edilir ve kayda geçer.

Karar tablosu — AI Fail-Safe Decision

Başarısızlık	Tanımladığınız güvenli davranış (hangi kavramla?)
Model yanlış sınıflandırdı	İkinci bağımsız ölçüm + örnekleme + insan onayı (human override, monitoring); eşik aşılırsa fail-safe
Girdi manipüle edildi	Bütünlük kontrolü; şüpheli girdi reddi (fail-safe, monitoring)
Confidence düştü	Confidence threshold altında kabul yok; fallback: insan veya dur

Bu föyün çıktısı **AI Fail-Safe Decision** → Evidence Pack **EP 03 + EP 15** başlığına oturur.